Arquitectura de datos de Prosta-AI

Yeison Bolaños Ruiz

Juan David Riascos Erazo

Sergio Gabriel Meneses Silva

Yimis Buenaventura

Fernando José Angulo Núñez

Facultad de Ingeniería, Universidad Santiago de Cali

Programa de Ingeniería de Sistemas

Gestión de Proyectos de TI

Jair Enrique Sanclemente Castro

22 de octubre de 2026

Arquitectura de datos de Prosta-AI

Definición

La arquitectura de datos describe cómo se gestionan los datos de un sistema, desde que se recopilan hasta que se transforman, se distribuyen y se consumen; es el plano técnico de cómo fluyen los datos por los sistemas de almacenamiento (IBM, s. f.). Dentro del proceso de diseño de software, Sommerville (2011) ubica el diseño de base de datos como una de las actividades de diseño, junto con el diseño arquitectónico, el de interfaz y el de componentes, y su salida es la especificación de la base de datos.

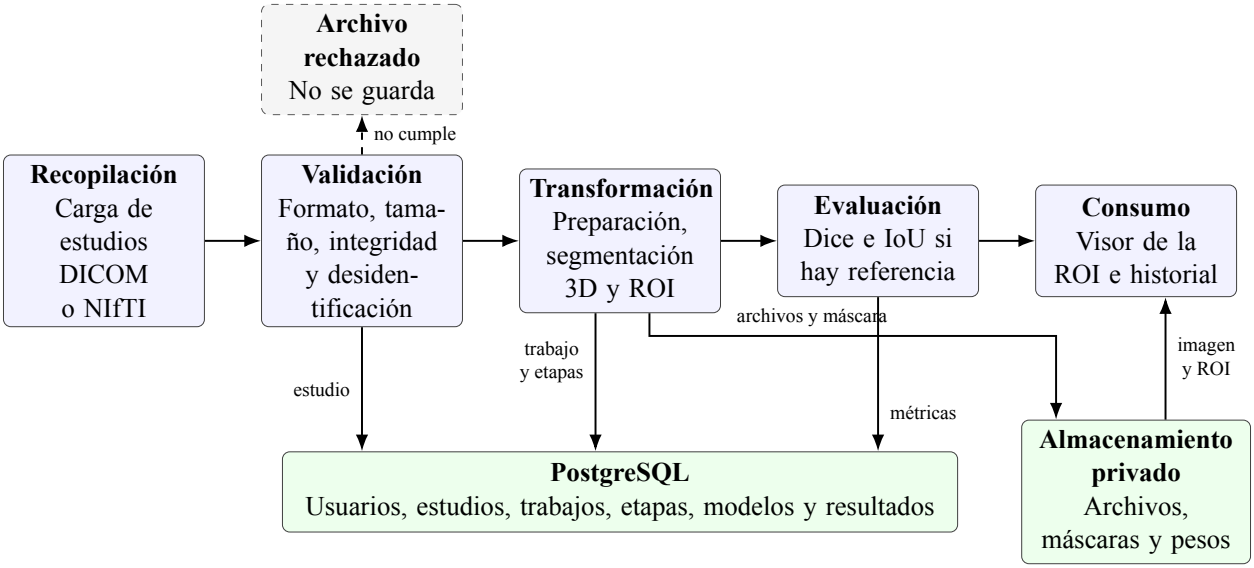
El diseño de una base de datos define su estructura lógica y física: las tablas, los atributos, las relaciones y las restricciones entre las entidades, así como las claves primarias y foráneas de cada tabla. Ese diseño parte de las necesidades de información de los usuarios y de las aplicaciones que usarán la base de datos (Casas Roma, s. f.).

Este documento corresponde al paquete 1.3.2.5 de la EDT (arquitectura de datos) y a la actividad 1309 del Ciclo 2, *Diseñar la base de datos*. Se basa en la matriz de trazabilidad de requisitos y en las arquitecturas de software y de sistema del proyecto (Equipo Prosta-AI, 2026a, 2026b).

Flujo de los datos

En Prosta-AI los datos siguen el recorrido de la Figura 1. Los estudios de prueba se recopilan cuando el usuario los carga; se validan y se desidentifican antes de guardarse; se transforman durante la preparación y la segmentación, y se consumen en el visor de la ROI y en el historial de estudios. La base de datos guarda la información estructurada (usuarios, estudios, trabajos, etapas, modelos y resultados), mientras que los archivos pesados (imágenes, máscaras y pesos del modelo) quedan en el almacenamiento privado y la base de datos solo guarda su ubicación.

Figura 1
Flujo de los datos en Prosta-AI



Nota. Los datos públicos de entrenamiento se usan fuera de la aplicación, en Google Colab; al sistema solo llegan los pesos del modelo entrenado. Elaboración propia.

Diseño de la base de datos

El diseño siguió las cinco fases del proceso de diseño de bases de datos (Casas Roma, s. f.).

Fase 1. Recogida y análisis de requisitos

Los requisitos de información se tomaron de la matriz de trazabilidad (Equipo Prosta-AI, 2026a) y se resumen en la Tabla 1.

Tabla 1
Requisitos que determinan la base de datos

Requisito	Necesidad de información	Efecto en el diseño
4.7	Acceso con nombre de usuario y contraseña, y creación de usuarios nuevos.	Entidad Usuario con alias único y contraseña cifrada.
2.2	Ningún dato que identifique a una persona queda almacenado.	Sin nombres, correos ni datos de pacientes; los estudios se identifican con un código anónimo.
4.1	Carga de uno o varios archivos DICOM o NIfTI por estudio.	Entidades Estudio y Archivo, con el formato y el resultado de la validación.
4.2	Estado del procesamiento y de cada etapa.	Entidades Trabajo y Etapa, con los estados de la arquitectura.

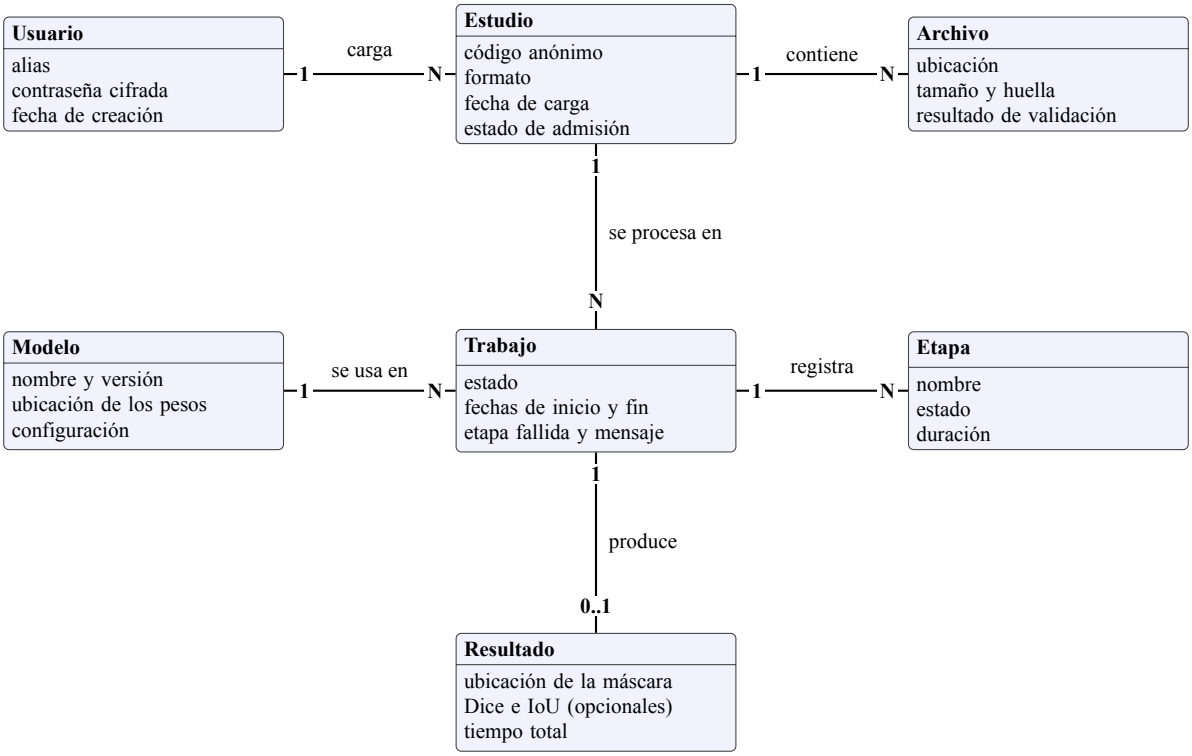
Requisito	Necesidad de información	Efecto en el diseño
4.5	Registro de estudios, resultados y métricas para consultarlos después.	Entidad Resultado ligada al trabajo que la produjo.
3.5 y 5.1	Dice, IoU y tiempo de procesamiento.	Atributos de métricas y duración por etapa y por trabajo.
5.4	Reproducibilidad: saber con qué modelo se obtuvo cada resultado.	Entidad Modelo con versión, ubicación y huella de los pesos.

Fase 2. Diseño conceptual

La Figura 2 presenta el esquema conceptual, independiente de la tecnología. Un usuario carga varios estudios; cada estudio tiene uno o varios archivos y puede procesarse más de una vez, porque un trabajo fallido se puede reintentar. Cada trabajo usa una versión del modelo, registra sus etapas y, si termina, produce un resultado.

Figura 2

Esquema conceptual de la base de datos



Nota. 1 = uno; N = varios; 0..1 = ninguno o uno. Elaboración propia.

Fase 3. Diseño lógico

El esquema conceptual se transforma en un modelo relacional, adecuado para PostgreSQL. Cada entidad se convierte en una tabla y cada relación de uno a varios, en una clave foránea en la tabla del lado de varios (Tabla 2).

Tabla 2
Modelo relacional

Tabla	Atributos	Claves
usuario	id_usuario, alias, hash_contrasena, fecha_creacion	PK: id_usuario; alias único
estudio	id_estudio, codigo_anonimo, id_usuario, formato, fecha_carga, estado_admision	PK: id_estudio; FK: id_usuario; código único
archivo	id_archivo, id_estudio, ruta, tamano_bytes, hash_sha256, valido	PK: id_archivo; FK: id_estudio
modelo	id_modelo, nombre, version, ruta_pesos, hash_pesos, ruta_configuracion, fecha_registro	PK: id_modelo; nombre y versión únicos
trabajo	id_trabajo, id_estudio, id_modelo, estado, fecha_creacion, fecha_inicio, fecha_fin, etapa_fallida, mensaje_error	PK: id_trabajo; FK: id_estudio, id_modelo
etapa_trabajo	id_etapa, id_trabajo, nombre, estado, fecha_inicio, fecha_fin, duracion_s	PK: id_etapa; FK: id_trabajo
resultado	id_resultado, id_trabajo, ruta_mascara, dice, iou, tiempo_total_s, fecha_registro	PK: id_resultado; FK: id_trabajo (único)

El estado que se muestra en Mis estudios (completado, listo para procesar o no compatible) se obtiene del estado de admisión del estudio y del último trabajo asociado, por lo que no se guarda dos veces.

Fase 4. Diseño físico

El modelo lógico se adapta a PostgreSQL con las decisiones de la Tabla 3.

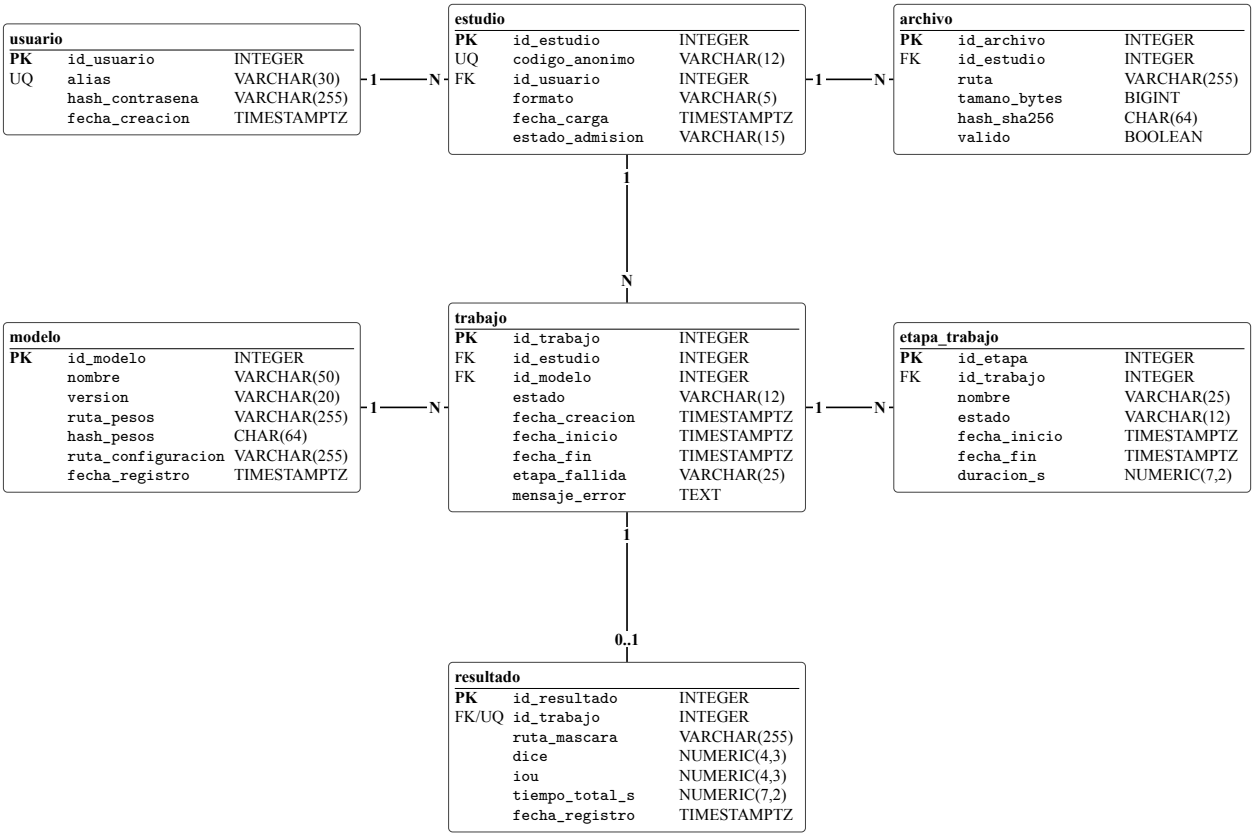
Tabla 3
Decisiones de diseño físico en PostgreSQL

Aspecto	Decisión
Identificadores	Enteros autogenerados (*identity*) como claves primarias; el código anónimo (por ejemplo, EST-0264) es el identificador que ve el usuario.
Tipos de datos	Texto de longitud limitada para alias, códigos y rutas; fechas con zona horaria; Dice e IoU como valores decimales entre 0 y 1, nulos si no hay referencia.
Restricciones	Listas cerradas para formato (DICOM, NIfTI), estado de admisión (admitido, no compatible), estado del trabajo (pendiente, en proceso, completado, fallido) y nombre de la etapa (control de calidad, preparación, segmentación, ROI, evaluación).
Integridad	Borrado en cascada de archivos, trabajos, etapas y resultados cuando se elimina un estudio.
Índices	Sobre el estado del trabajo, porque la tarea de procesamiento consulta los trabajos pendientes, y sobre el usuario del estudio, para el historial de Mis estudios.
Contraseñas	Solo se guarda el resultado de un algoritmo de hash con sal (por ejemplo, bcrypt); nunca la contraseña.
Archivos	Las imágenes, máscaras y pesos se guardan en el almacenamiento privado; la base de datos solo conserva su ruta y su huella (hash), sin metadatos identificables.

La Figura 3 muestra el diagrama relacional resultante, con las claves de cada tabla y los tipos de datos de PostgreSQL.

Figura 3

Diagrama relacional de la base de datos



Nota. PK = clave primaria; FK = clave foránea; UQ = valor único. Cada línea une la clave foránea con la clave primaria de la tabla relacionada. Elaboración propia.

Fase 5. Implementación y optimización

La base de datos se creará en el Ciclo 6 con scripts de migración versionados en el repositorio, dentro de la actividad 1703, *Conectar la base de datos y los archivos almacenados*. Se cargará con estudios públicos de prueba y se verificará que no contenga datos personales (actividad 1711). La optimización se limitará a lo que muestren las pruebas de rendimiento: revisar los índices si la consulta de trabajos pendientes o del historial se vuelve lenta, y limpiar los archivos temporales de los estudios rechazados.

Referencias

Casas Roma, J. (s. f.). *Introducción al diseño de bases de datos* (PID_00213710). Fundació per a la Universitat Oberta de Catalunya. https://gc.scalahed.com/recursos/files/r161r/w25213w/M1CDN112_S1_Introduccion_al_diseno_de_base

Equipo Prosta-AI. (2026a). *Matriz de trazabilidad de requisitos Prosta-AI* [Documento no publicado]. Universidad Santiago de Cali.

Equipo Prosta-AI. (2026b). *Arquitectura de software de Prosta-AI* [Documento no publicado]. Universidad Santiago de Cali.

IBM. (s. f.). *¿Qué es la arquitectura de datos?* IBM Think. https://www.ibm.com/mx-es/think/topics/data-architecture

Sommerville, I. (2011). *Ingeniería de software* (9.ª ed.). Pearson Educación.